

Extração de Características de Imagens da Retina pelo uso do SURF e LBP para Detecção Automática do Glaucoma

Wallinson L. Silva¹, Maíla L. Claro¹, Leonardo M. Santos¹, Flávio H. D. Araújo¹

¹Campus Senador Helvídio Nunes de Barros (CSHNB) – Universidade Federal do Piauí (UFPI) – Picos – PI – Brasil

{iwallinsom, claromaila, leonardo.moura.software}@gmail.com,
flavio86@ufpi.edu.br

Abstract. *Glaucoma is an asymptomatic disease and is considered the second greater cause of blindness in the world, it attacks the optic nerve causing irreversible damage to the visual field. Although there is no cure exists treatment, which can be facilitated from a previous diagnosis. Thus, this work consists of methods for feature extraction in retinal images from the use of descriptors for the automatic detection of glaucoma. These methods are constructed from the use of visual dictionaries, which are robust forms of representation, and the Local Binary Pattern texture descriptor.*

Resumo. *O glaucoma é uma doença assintomática, sendo considerada a segunda maior causa de cegueira no mundo, ela ataca o nervo óptico causando danos irreversíveis no campo visual. Apesar de não haver cura, existe tratamento, que pode ser facilitado a partir de um prévio diagnóstico. Desse modo, esse trabalho consiste em métodos para extração de características em imagens de retina a partir do uso de descritores para a detecção automática do glaucoma. Esses métodos são construídos a partir da utilização de dicionários visuais, que são formas de representação robusta, e o descritor de textura Local Binary Pattern.*

1. Introdução

O glaucoma é uma doença que afeta o nervo óptico gradativamente, ocorrendo assim a perda progressiva do campo de visão de maneira irreversível. Esse dano óptico geralmente é causado pelo aumento da pressão dentro do olho (pressão intraocular) [Weinreb 2004].

Uma característica preocupante do glaucoma é o fato de não possuir sintomas, tornando-a cada vez mais grave e podendo ser notada somente em seu estado mais avançado, ocasionando assim a perda permanente da visão. Os danos causados pelo glaucoma podem ser reduzidos a partir do diagnóstico antecipado, sendo assim, sua detecção precoce é de grande importância. Existem vários métodos utilizados para o diagnóstico dessa doença, tais como: avaliação da pressão intraocular; exame da pupila, que detecta lesões no nervo óptico; e avaliação do campo visual.

De acordo com a Organização Mundial de Saúde (*World Health Organization*) [Who 2014], existem cerca de 60 milhões de glaucomatosos em todo o mundo, sendo que, a cada ano, surgem mais 2,4 milhões de casos. A prevalência da cegueira por glaucoma é de 5,2 milhões de pessoas, representando a segunda maior causa de cegueira

no mundo. Segundo Quigley (2006), em 2020, cerca de 80 milhões de pessoas terão glaucoma.

Uma maneira viável e de baixo custo, levando em consideração outras técnicas de detecção do glaucoma, é o diagnóstico feito a partir da análise de imagens de fundo de olho. Nessa técnica as imagens são analisadas por um especialista humano que tenta identificar o acúmulo do líquido ao redor do disco óptico.

O diagnóstico do glaucoma usando imagens também pode ser feito a partir de técnicas de processamento digital de imagens. As principais formas de detecção são por segmentação de regiões e por extração de características das imagens juntamente com técnicas de classificação de dados. Diante do exposto, neste trabalho foram utilizados o SURF e o LBP para extração de características das imagens de fundo de olho e a detecção automática do glaucoma.

2. Trabalhos Relacionados

O trabalho de Araújo *et al.* (2013), tinha como objetivo o diagnóstico da Retinopatia Diabética. Um dos métodos propostos utilizava o algoritmo *Speed-Up Robust Features* (SURF) para extração de características, porém o número de atributos retornados pelo algoritmo era diferente para cada imagem, dificultando o uso de classificadores. Para contornar essa situação, foram utilizados os dicionários visuais para gerar um único vetor de atributos para classificação. Por fim, o vetor de atributo encontrado foi utilizado para classificação das imagens em saudáveis ou patológicas.

O trabalho de Amaral e Thomaz (2012) tinha como finalidade avaliar as técnicas *Local Binary Pattern* (LBP) e *Principal Componentes Analysis* (PCA), encontrando as características faciais de maior importância no processo de reconhecimento, indicando a melhor solução para o problema de restrição amostral.

Silva *et al.* (2013) desenvolveram um sistema para detecção e classificação de motocicletas em vias públicas e detecção de motociclista sem capacete. Para atingir o objetivo os autores utilizaram um descritor híbrido para extração de características com base nos descritores *Local Binary Pattern* (LBP), *Histograms of Oriented Gradients* (HOG) e Transformada Circular de Hough (TCH). Esses descritores foram utilizados para extrair as características das imagens e em seguida, os vetores de atributos foram usados para classificação.

3. Base de Imagens

As imagens utilizadas neste trabalho foram retiradas da base RIM-ONE [Trucco *et al.* 2013]. Essa base de imagens foi fornecida por três hospitais: Hospital Universitário de Canarias, Hospital Clínico San Carlos e Hospital Universitário Miguel Servet. Ela contém imagens de fundo de olho fornecidas por diferentes especialistas, provendo assim diversas imagens de olhos saudáveis e com diferentes níveis de glaucoma. A base é separada por categorias, ou seja, saudáveis e glaucomatosas, característica essa que à adequou a nosso trabalho, pois outras bases não forneciam essa distinção de imagens. A Figura 1 apresenta duas imagens da base RIM-ONE.

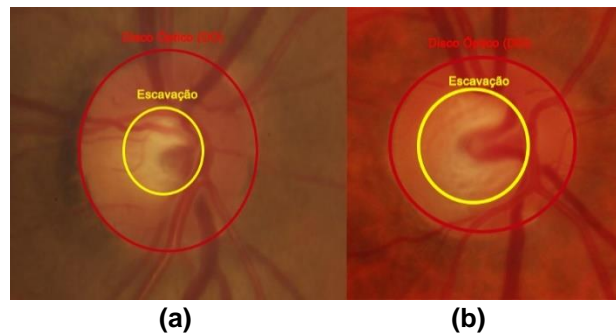


Figura 1. a) Retina saudável com a escavação do disco óptico normal, b) Retina glaucomatosa, evidenciando uma escavação mais avançada.

4. Método Proposto

O fluxograma apresentado na Figura 2 ilustra todos os passos realizados neste trabalho.



Figura 2. Fluxograma contendo os passos da metodologia proposta nesse trabalho.

Neste trabalho a etapa de Pré-Processamento teve como objetivo amenizar as diferenças de luminosidade entre as imagens e evidenciar suas características para a fase de Extração de Características com o SURF [Bay *et al.* 2006]. Inicialmente, as imagens foram convertidas para tons de cinza, e em seguida, foi realizada a equalização do histograma, de modo a melhorar seu contraste.

Na etapa da Extração de Características com o SURF, as imagens equalizadas foram submetidas à extração. O SURF por padrão retorna para cada ponto característico um vetor com 64 posições, esse vetor contém os valores que representarão a imagem numericamente. Nesse trabalho foi utilizado o valor de 128 posições, para melhor representar as imagens.

Apesar de ser uma boa opção para descrever imagens de forma mais detalhada, o uso de descritores locais pode se tornar uma grande dificuldade no momento da classificação das amostras. Eles retornam como saída um vetor de atributos que varia de acordo com a imagem, devido a isso não há o controle da quantidade de atributos descritos. Tendo em vista essa inconsistência, os classificadores não conseguem trabalhar bem com representações geradas pelos descritores locais [Carvalho 2010].

Para solucionar a dificuldade dos classificadores tem-se como opção a utilização dos dicionários visuais.

Os dicionários são uma forma de representação robusta para imagens onde cada imagem é vista apenas como uma coleção de regiões nas quais a informação espacial da região não importa. A única informação considerada é a aparência da região [Tinne *et al.* 2008]. Os dicionários visuais são matrizes compostas por palavras (linhas da matriz) que são feitas pelos pontos mais representativos da imagem extraídos pelo algoritmo SURF. Esses dicionários são usados para capturar as propriedades comuns entre as regiões marcadas pelo algoritmo SURF [Araujo *et al.* 2013].

Na etapa de Criação dos Dicionários Visuais as duas matrizes com os atributos extraídos passaram por um processo de agrupamento. O algoritmo utilizado para agrupamento foi o k-means. Esse algoritmo dividiu a matriz em 128 e selecionou os atributos que melhor representaram cada um desses clusters.

Para gerar as assinaturas das imagens, o processo realizado foi basicamente o mesmo da constituição do dicionário visual. Primeiramente, as imagens passaram pela etapa de Pré-processamento, depois, suas características foram extraídas com SURF, resultando em duas matrizes, uma com atributos doentes e outra com atributos saudáveis. A assinatura é a representação de uma imagem por meio de um vetor, construído a partir do dicionário visual, sendo inicialmente composto apenas por zeros. Para gerar a assinatura foi feita a comparação de cada atributo da imagem com todas as linhas (palavras) do dicionário, calculando a diferença entre o atributo e a linha do dicionário, assim, a posição que possuía a menor diferença foi localizada. Além disso, foi incrementada em uma unidade a respectiva posição no vetor, ocorrendo esse processo para todos os atributos de todas as imagens.

A fase de extração de características com LBP [Ojala *et al.* 1996] ocorre com as imagens originais. Ele é um descritor de textura, que cria janelas 3x3 a partir da imagem original e compara o pixel central com seus 8 vizinhos. Assim, uma matriz binária é criada onde os valores menores que o pixel central recebem valor zero e os maiores recebem um. Feito isso, foi gerada uma matriz 3x3 contendo como pesos, os valores baseados em potências de 2. Os valores da matriz binária foram multiplicados por os valores da matriz de peso, assim, foram somados os resultados da multiplicação, sendo esse resultado armazenado em um histograma de 0 a 255.

Por fim, para realizar a classificação das imagens, foram concatenados as assinaturas geradas juntamente com o histograma obtido de cada imagem por meio do LBP, gerando um vetor de 512 atributos.

5. Resultados e Discussões

Na avaliação do algoritmo desenvolvido, 20 imagens saudáveis e 15 doentes foram utilizadas na construção do dicionário visual. Já na verificação do desempenho do algoritmo, foram testadas 98 imagens saudáveis e 25 doentes, em que tiveram suas assinaturas geradas e seus histogramas LBP concatenados à assinatura.

O software utilizado para classificação foi o *Waikato Environment for Knowledge Analysis* (WEKA) [Witten *et al.* 2011]. Os algoritmos testados nesse trabalho foram: *Random Forest* [Breiman 2001], C4.5 [Quinlan 1986] *Radial Basis Function* (RBF) *Classifier* [Frank 2014], *Simple Logistic* [Landwehr *et al.* 2005] e *Logistic Model Trees* (LMT) [Landwehr *et al.* 2005]. Os resultados de precisão, *recall*, acurácia e kappa [Rosenfield e Fitzpatrick-lins 1986] encontrados para cada um dos classificadores são apresentados na Tabela 1.

Tabela 1. Resultado dos melhores classificadores.

	Precisão	<i>Recall</i>	Acurácia	Kappa
<i>Random Forest</i>	87,40	87,80	87,81	0,61
C4.5	87,50	87,90	87,92	0,62
RBF	89,00	89,40	89,43	0,64
<i>Simple Logistic</i>	90,10	90,20	90,25	0,66
LMT	92,60	92,70	92,68	0,76

Os parâmetros utilizados para classificação foram os padrões do WEKA e o critério de avaliação foi o *k-fold cross-validation* (com $k = 10$). Todos os classificadores obtiveram resultados satisfatórios, contudo o que mais se destacou foi o LMT, por ter alcançado os melhores índices, com acurácia de mais 92% e kappa de 0,76. Os resultados comprovam a eficiência da extração de características atingindo índices considerados bons segundo literaturas.

6. Conclusão e Trabalhos Futuros

O PDI está evoluindo rapidamente tornando-se uma ferramenta de auxílio em todas as áreas. Na medicina o diagnóstico de doenças por PDI traz rapidez, confiabilidade e redução de custo.

Esse trabalho apresentou uma forma de detecção automática do Glaucoma em imagens do fundo de olho da retina. Para a extração das características das imagens foram utilizados o SURF e o LBP e os resultados obtidos foram bastante satisfatórios, com cerca de 92.68% de acurácia, totalizando um kappa de 0.76.

Como trabalhos futuros, espera-se utilizar novos descritores para a extração de características das imagens, e novos classificadores para avaliação. Por fim, serão implementados métodos de detecção automática do Glaucoma em imagens de retina existentes na literatura e comparados com o método proposto nesse trabalho.

7. Referências Bibliográficas

Amaral, V. e Thomaz, C. E. (2012) “Extração e Comparação de Características Locais e Globais para o Reconhecimento Automático de Imagens de Faces”. XIII Workshop de Visão Computacional (WVC), São Bernardo do Campo, São Paulo – Brasil.

- Araújo, F., Silva, R., Macedo, A., Aires, K. e Veras, R. (2013) “Automatic Identification of Diabetic Retinopathy in Retinal Images Using Ensemble Learning”. Workshop de Informática Médica, Maceió, Alagoas, Brasil.
- Bay, H., Tuytelaars, T. e Gool, L. V. (2006) “Surf”: Speeded up robust features. European Conference on Computer Vision, p 404–417.
- Breiman, L. (2001) “Random forests”. Machine Learning, 45(1):5–32.
- Carvalho, T. J. (2010) “Aplicação de Técnicas de Visão Computacional e Aprendizado de Máquina para a Detecção de Exsudatos Duros em Imagens de Fundo de Olho”. Dissertação de Mestrado em Ciência da Computação, Instituto de Computação, Universidade Estadual de Campinas, Campinas, Brasil.
- Frank, E. (2014) “Fully supervised training of Gaussian radial basis function networks in WEKA”. Department of Computer Science, The University of Waikato.
- Landwehr, N., Hall, M. e Frank, E. (2005). Logistic model trees. Machine Learning, 59(1-2):161–205.
- Ojala, T., Pietikinen, M. e Harwood, D. (1996). “A comparative study of texture measures with classification based on featured distributions”, Pattern Recognition 26(1): 51–59.
- Quigley, H. A. e Broman, A. T. (2006) “The number of people with glaucoma worldwide in 2010 and 2020”. Br J Ophthalmol. 90(3): p. 262-7.
- Quinlan, J. R. (1986). “Induction of decision tree”. Machine Learning, 1(1): 81–106.
- Rosenfield, G. H. e Fitzpatrick-lins, K. A. (1986). “A coefficient of agreement as a measure of thematic classification accuracy”. Photogrammetric Engineering and Remote Sensing, 52:223–227.
- Silva, R., Aires, K., Santos, T., Abdalla, K. e Veras, R. (2013) “Segmentação, classificação e detecção de motociclistas sem capacete”. XI Simpósio Brasileiro de Automação Inteligente (SBAI), Fortaleza, Ceará – Brasil.
- Tinne, T., Gool, L. V., Bay, H. e Andreas, E. (2008) “Speeded-up robust features (SURF)”. Computer Vision Image Understand, 110(3):346–359, 2008.
- Trucco, E., Ruggeri, A., Karnowski, T., Giancardo, L., Chaum, E., Hubschman, J. P., Al-Diri, B., Cheung, C. Y., Wong, D., Abràmoff, M., Lim, G., Kumar, D., Burlina, P., Bressler, N. M., Jelinek, H. F., Meriaudeau, F., Quéllec, G., Macgillivray, T. e Dhillon, B. (2013) “Validating Retinal Fundus Image Analysis Algorithms”: Issues And A Proposal. Invest. Ophthalmol. Vis. Sci., vol. 54, no. 5, pp. 3546–3559.
- Weinrb, R. N. e Khaw, P. T. (2004) “Primary opne-angle glaucoma”. The Lancet.
- Witten, I. H., Frank, E., e Hall, M. A. (2011). “DATA MINING”: Practical Machine Learning Tools and Techniques. Morgan Kaufmann, 3 edition.
- WHO. “World health organization (WHO)”. Disponível em: <http://apps.who.int/ghodata/?vid=5200>, 2014, acessado em Setembro de 2014.